# Previsão de preços de imóveis nos distritos de Londres

Estudo de Machine Learning | Regressão linear simples, múltipla e polinomial | Dados de 1999 a 2019

## Resumo executivo

Este estudo compara modelos de regressão para estimar o preço médio de imóveis por distrito de Londres no mês de dezembro, utilizando indicadores socioeconômicos. Foram analisados 693 registros de 33 distritos ao longo de 21 anos. A avaliação foi conduzida por divisão entre distritos de treino, validação e teste, para medir generalização a áreas não vistas no treinamento.

Na validação, a regressão múltipla apresentou menor RMSE (£ 107.852). No teste reservado, entretanto, o polinômio de grau 2 teve o menor RMSE (£ 249.094), e todos os modelos superaram apenas modestamente o baseline. As previsões são insuficientes para decisões imobiliárias de maior impacto, especialmente em distritos de alto preço.

## Problema e hipótese

O alvo é o preço médio de venda de imóveis em libras esterlinas (£) para cada distrito/ano. Busca-se avaliar se salário mediano, número de empregos e porcentagem de reciclagem contêm sinal preditivo. Como critério de utilidade prática, o estudo adotou previamente um MAE desejável de até £ 50 mil; esse limite não foi alcançado.

## Dados utilizados

Fonte: Housing in London, publicado por Justinas Cirtautas no Kaggle (com origem indicada no London Datastore). Foram combinados os arquivos mensais e anuais; o conjunto analítico usa 693 observações de dezembro, correspondentes a 33 distritos e 21 anos (1999–2019). Cada linha descreve estatísticas agregadas de um distrito, e não uma venda individual.

| Variável | Função no modelo |
|---|---|
| average_price | Alvo: preço médio em £ |
| median_salary | Preditor principal, em £/ano |
| number_of_jobs | Preditor adicional: número de empregos |
| recycling_pct | Preditor adicional: percentual reciclado |

## Preparação dos dados e prevenção de vazamento

Os marcadores de ausência “na” e “#” foram convertidos em valores ausentes; há 10 ausências em median_salary, 66 em number_of_jobs e 34 em recycling_pct, sem duplicatas exatas. Todas as 693 linhas foram mantidas, inclusive distritos com preços extremos. A imputação por mediana e a padronização foram aplicadas dentro de um Pipeline, com parâmetros ajustados exclusivamente nos dados de treino (ou treino + validação no reajuste final).

## Por que separar por distrito, e não aleatoriamente por linha?

Como há observações repetidas dos mesmos distritos ao longo dos anos, uma separação por linha poderia fazer o modelo encontrar no teste distritos já presentes no treino. Para reduzir esse problema, a divisão foi feita pelo identificador do distrito, com random_state=42: 19 distritos no

treino (399 registros), 7 na validação (147) e 7 no teste (147). Essa divisão não avalia generalização temporal; os conjuntos compartilham anos.

## Modelos avaliados

Foi comparado um baseline (DummyRegressor pela média de treino), uma regressão linear simples (median_salary), regressão múltipla (median_salary, number_of_jobs e recycling_pct) e modelos polinomiais de graus 2, 3 e 5 sobre median_salary. Os coeficientes foram ajustados via mínimos quadrados. O grau polinomial é um hiperparâmetro escolhido pela validação, não um peso aprendido automaticamente.

## Como interpretar os coeficientes?

Na regressão linear simples, o coeficiente reconvertido foi 18,91: um aumento de £ 1 no salário mediano anual esteve associado a aproximadamente £ 18,91 no preço médio estimado, sem implicar causalidade. Na regressão múltipla, o coeficiente do salário caiu para 13,39 ao considerar empregos e reciclagem, em parte porque salário e empregos apresentaram correlação de 0,64 no treino.

## Resultados de validação (modelos ajustados apenas no treino)

| Modelo | RMSE (£) | $R^2$ |
|---|---|---|
| Baseline | 136.130 | −0,433 |
| Linear simples | 137.638 | −0,465 |
| Linear múltipla | 107.852 | 0,100 |
| Polinomial grau 2 | 141.758 | −0,554 |
| Polinomial grau 3 | 152.369 | −0,795 |
| Polinomial grau 5 | 152.969 | −0,810 |

## O aumento do grau trouxe sobreajuste?

Sim, há evidência no contraste entre treino e validação: o RMSE do treino diminuiu à medida que o grau aumentou, enquanto o RMSE de validação piorou. Entre os polinômios testados, o grau 2 foi o selecionado antes do teste; ainda assim, todos os polinômios tiveram desempenho de validação inferior ao baseline. O modelo múltiplo foi o recomendado com base exclusivamente na validação.

## Avaliação final em distritos não vistos

Depois de fixar as escolhas, os modelos foram reajustados em treino + validação e avaliados uma única vez no teste reservado. Os resultados são apresentados sem trocar a seleção retrospectivamente.

| Modelo | MAE (£) | RMSE (£) | $R^2$ |
|---|---|---|---|
| Baseline | 169.966 | 270.542 | −0,064 |
| Linear simples | 137.579 | 254.067 | 0,062 |
| Linear múltipla | 139.172 | 256.869 | 0,041 |
| Polinomial grau 2 | 137.459 | 249.094 | 0,098 |

## Por que a escolha da validação não se confirmou integralmente no teste?

Embora a regressão múltipla tenha sido a melhor na validação, seu RMSE no teste foi de £ 256.869, acima do polinomial de grau 2 (£ 249.094). Todos melhoraram pouco o RMSE frente ao baseline (£ 270.542); a vantagem da múltipla na validação não se repetiu. O $R^2$ de teste permaneceu baixo, entre aproximadamente 0,04 e 0,10.

## Diagnóstico dos erros e exemplos

Os modelos subestimaram sistematicamente distritos de preços muito altos. Em Kensington and Chelsea, um registro de dezembro de 2016 apresentou preço real de £ 1.357.231 e previsão de £ 328.692 pela regressão múltipla — erro de £ 1.028.539. Em Ealing, dezembro de 2003, a mesma abordagem apresentou erro de apenas £ 902. Essa discrepância aponta para heterogeneidade não capturada pelas variáveis selecionadas.

## Limitações e próximos experimentos

A base reúne somente 33 unidades geográficas independentes; usa indicadores agregados, não descreve imóveis individuais, e não contém características críticas como localização detalhada, tipo e área construída. Preços e salários não foram explicitamente corrigidos por inflação. O teste por distrito não substitui uma avaliação temporal. O trabalho sugere como próximos passos: GroupKFold por distrito, atributos de localização e ano, transformação logarítmica do alvo e regressão Ridge. Tais experimentos são propostas futuras, não resultados já obtidos.

## Reprodução e fontes

Dataset: https://www.kaggle.com/datasets/justinas/housing-in-london

Colab de referência: https://colab.research.google.com/drive/13SiWMGaCONki5tDiL_XQwpu5aDSjt2vf?usp=sharing

Reprodução conforme o relatório original: disponibilizar os CSVs housing_in_london_monthly_variables.csv e housing_in_london_yearly_variables.csv em /content no Colab e executar o notebook em sequência. Documentação técnica: https://scikit-learn.org/stable/

As metodologias, os valores numéricos e as limitações foram transcritos e reorganizados do relatório fornecido. As métricas não foram recalculadas nesta edição. A estrutura de funções do notebook foi adaptada de material de laboratório acadêmico, conforme atribuição constante no relatório original.